

Curso: EIF-4200 Inteligencia Artificial I Semestre 2026

Valor %: 20

Prof.: Lic. Adán Carranza Alfaro

IV Proyecto de Investigación Dirigida

Naturaleza: Teórico-Práctico

Fecha de Entrega: 06 de junio del 2026 00:00

El Estado del Arte en Procesamiento de Lenguaje Natural (PLN)

Objetivo Académico

Realizar una investigación profunda y crítica sobre los pilares del PLN, analizando la transición desde modelos estadísticos tradicionales hasta la era de los Large Language Models (LLMs) y las arquitecturas de atención, fundamentando el análisis en literatura científica reciente.

Estructura y Requisitos del Documento (Mínimo 5 páginas)

1. Fundamentos y Evolución del PLN

Definición Sistémica: Más allá de una definición básica, describir el PLN como la intersección entre la lingüística computacional y el aprendizaje profundo (*Deep Learning*).

Desafíos Ontológicos: Analizar no solo la ambigüedad, sino también el sesgo algorítmico, la alucinación en modelos generativos y el desafío de la comprensión del pragmatismo (ironía, sarcasmo y dobles sentidos).

Ecosistema de Aplicaciones: Clasificar las aplicaciones en:

- *NLU (Comprensión):* Análisis de sentimiento, clasificación de documentos.
- *NLG (Generación):* Resumen automático, agentes conversacionales autónomos.

2. Arquitecturas y Modelos de Lenguaje (La Revolución de los Transformers)

Debe profundizar en la jerarquía técnica de los modelos:

- Modelos Probabilísticos (N-Gramas): Su rol histórico en la predicción basada en frecuencia.
- Arquitecturas Recurrentes (RNN y LSTM): Explicar el problema del gradiente desvaneciente y por qué fueron superadas.
- El Cambio de Paradigma (Transformers):
 - i) Análisis detallado del mecanismo de Auto-Atención (Self-Attention).
 - ii) BERT vs. GPT: Diferencias entre modelos codificadores (comprensión) y decodificadores (generación).
 - iii) Explicar el concepto de Few-shot learning en modelos modernos.

3. Pipeline de Ingeniería Lingüística (Técnicas de Procesamiento)

Describir el proceso de transformación de datos crudos a tensores numéricos:

- Normalización Avanzada: Comparar *Stemming* vs. *Lemmatización* y cuándo usar cada uno en contextos de alta precisión.
- Tokenización por Subpalabras: Explicar técnicas modernas como BPE (Byte Pair Encoding) utilizadas por GPT, en lugar de solo dividir por espacios.
- Enriquecimiento Sintáctico (POS Tagging & NER): La importancia del Etiquetado Gramatical y el Reconocimiento de Entidades Nombradas (NER) para la extracción de información.
- Embeddings (Vectorización): Explicar cómo las palabras se convierten en vectores en un espacio multidimensional (Word2Vec a Embeddings Contextuales).

4. Bibliografía y Referencias (Norma APA 7ma Ed.)

- Actualidad Obligatoria: Las fuentes deben ser de 2020 a 2026.
- Fuentes de Autoridad: Se requiere la inclusión de "Papers" de conferencias como ACL, EMNLP, o NeurIPS, y referencias a documentación oficial de librerías líderes (Hugging Face, spaCy, OpenAI).

Parte 2: Sistema Inteligente de Análisis de Feedback y Sentimiento del Cliente Enunciado del Proyecto

Una empresa de comercio electrónico recibe miles de reseñas y comentarios diariamente. Para mejorar su toma de decisiones, requiere un sistema de Análisis de Sentimiento y Minería de Texto que no solo clasifique comentarios, sino que identifique las palabras clave más recurrentes y presente los datos de forma visual para la gerencia. Usted debe desarrollar una aplicación en Python que procese estos datos utilizando modelos avanzados de PLN.

Objetivo General

Desarrollar una herramienta integral de procesamiento de lenguaje que analice entradas de texto masivas, determine la polaridad emocional, normalice el lenguaje mediante lematización y genere visualizaciones de datos (Nubes de Palabras y Gráficos de Sentimiento) para extraer *insights* de negocio.

Requisitos del Sistema (Nivel Avanzado)

1. Procesamiento Multitarea (Pipeline de PLN)

En lugar de elegir una sola tarea, el sistema debe realizar un flujo completo:

- Limpieza de Datos: Eliminación de *stop words* (palabras vacías como "el", "de", "con") y caracteres especiales.
- Normalización Estructural: Implementar Tokenización y Lematización (usando spaCy para español o inglés) para reducir el ruido léxico.
- Análisis de Sentimiento: Clasificar el texto en Positivo, Neutro o Negativo.

2. Interfaz y Visualización de Resultados

El sistema no debe limitarse a imprimir texto en consola. Debe incluir:

- Dashboard Visual: Generar una Nube de Palabras (WordCloud) con los términos más frecuentes (lematizados) para entender de qué hablan los clientes.
- Métricas Gráficas: Un gráfico de barras o pastel que muestre la distribución de sentimientos del conjunto de datos analizado (usando matplotlib o seaborn).

3. Implementación Técnica Sugerida

- Motor de PLN: spaCy (por su eficiencia industrial) o NLTK con VADER / TextBlob.
- Entrada de Datos: El programa debe permitir cargar un archivo de texto (.txt) o un archivo de Excel/CSV con múltiples comentarios para análisis por lote (*batch processing*).

4. Evaluación y Reporte

- Validación: Presentar un cuadro comparativo entre el texto original y el procesado (Lematizado).

- **Análisis de Precisión:** Evaluar si el modelo detecta sarcasmo o negaciones básicas (ej: "No es bueno" vs "Es bueno").

Requisito de Presencia en la Defensa Técnica (Video)

La participación visual y auditiva de cada estudiante en el video de YouTube es un requisito indispensable para la validación de la nota.

- **Condición:** Todo integrante del grupo debe aparecer en pantalla y explicar una sección técnica del proyecto (Investigación, Código o Demostración).
- **Sanción:** El estudiante que NO aparezca activamente en el video de defensa recibirá una calificación de 0 (CERO) en la nota total del PID, sin excepción alguna. Esta medida garantiza la integridad académica y certifica la autoría del desarrollo presentado.

Excepciones: Melannie Oviedo.

Criterios de evaluación del PID:

Categoría	Criterio de Evaluación	Descripción Técnica (Nivel Profesional)	Puntaje
Investigación (Teoría)	Estado del Arte en PLN	Calidad de la investigación (5 págs): Análisis de Transformers (BERT/GPT), desafíos éticos y bibliografía 2020-2026.	25 pts
Desarrollo (Práctica)	Pipeline de Ingeniería	Implementación de limpieza, tokenización avanzada y lematización usando modelos de lenguaje (ej. <code>es_core_news_lg</code>).	15 pts
	Análisis de Sentimiento	Uso de modelos de polaridad (TextBlob, Vader o modelos de HuggingFace) para clasificar en Positivo, Negativo y Neutro.	15 pts
	Dashboard Visual	Generación de Nube de Palabras dinámica y gráficos estadísticos (Matplotlib/Seaborn) sobre el volumen de sentimientos.	10 pts
	Ingesta de Datos	Capacidad de procesar lotes de datos desde archivos CSV, Excel o JSON , simulando una auditoría real de clientes.	10 pts
Calidad de Software	Estructura Modular	Código organizado en clases/módulos, uso de entornos virtuales y documentación interna clara.	10 pts
	Robustez y Errores	Manejo de excepciones: Control de archivos corruptos, textos en idiomas no soportados y logs de error.	5 pts
Comunicación	Defensa Técnica (Video)	Explicación clara en YouTube sobre la arquitectura del pipeline, los hallazgos en los datos y las conclusiones del modelo.	10 pts
TOTAL			100 pts